

FUNDAÇÃO GETÚLIO VARGAS

INFERÊNCIA ESTATÍSTICA

Trabalho III: Análise Bayesiana

Rener de Souza Oliveira
rener.oliveira@fgv.edu.br

Rio de Janeiro, RJ
20 de Outubro de 2020

Conteúdo

1	Introdução	2
2	A distribuição Normal-Gama	2
2.1	Distribuições à posteriori	3
2.2	Análise dos hiperparâmetros	5
3	A distribuição marginal de μ	6
4	O Dilema da Palmirinha	7
4.1	Posterioris	7
4.2	Intervalos de Credibilidade	7

1 Introdução

"Neste trabalho, vamos derivar os principais resultados de uma análise bayesiana conjugada de dados normalmente distribuídos. Para tal, começamos com uma reparametrização. Em particular, fazemos $\tau = 1/\sigma^2$, de modo que os parâmetros de interesse $\theta = (\mu, \sigma^2)$ se tornem $\phi = (\mu, \tau)$. O parâmetro τ é chamado de *precisão*. Suponha que observamos uma amostra aleatória X_1, \dots, X_n com distribuição normal com parâmetros μ e τ , ambos desconhecidos"¹

2 A distribuição Normal-Gama

Iremos derivar uma família de distribuições que serão conjugadas que funcionará como priori conjugada para ϕ . Ou seja, dada uma priori para ϕ de distribuição normal-gama, teremos que a distribuição da posteriori também será normal-gama.

Primeiramente, vamos determinar a distribuição conjunta condicional dos dados sob a nova parametrização. Para um dado $X_i \sim \text{Normal}(\mu, \sigma^2)$ temos a distribuição de densidade de probabilidade como:

$$f(x_i|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{1}{2} \frac{(x_i - \mu)^2}{\sigma^2} \right]$$

Fazendo $\sigma^2 = 1/\tau$, temos:

$$f(x_i|\mu, \tau) = \sqrt{\frac{\tau}{2\pi}} \exp \left[-\frac{\tau}{2} (x_i - \mu)^2 \right]$$

Usaremos a notação $X_i \sim \text{Normal}_2(\mu, \tau)$, para se referir à esta nova parametrização que utiliza precisão.

Assumindo que os dados são independentes e identicamente distribuídos, temos que a função de verossimilhança, ou distribuição conjunta condicional dos dados é:

$$\begin{aligned} f(\vec{X}|\phi) &= \prod_{i=1}^n f(x_i|\phi) \\ &= \left(\frac{\tau}{2\pi} \right)^{n/2} \exp \left[-\frac{\tau}{2} \sum_{i=1}^n (x_i - \mu)^2 \right] \end{aligned} \quad (1)$$

Vamos assumir que a distribuição à priori de τ é Gama(α_0, β_0) e a distribuição à priori condicional de $\mu|\tau$ é Normal de média μ_0 e precisão $\lambda_0\tau$. Essa é uma premissa razoável por dois motivos: o primeiro é o que o espaço de definição dos parâmetros coincide com o espaço onde as densidades das distribuições citadas estão definidas, μ é definido na reta assim como a normal, e τ é definido para os positivos assim como a gama; o segundo motivo é que pela expressão da verossimilhança (1), se multiplicarmos com a densidade de uma normal, a forma funcional parece que também irá se comportar como uma normal, o mesmo ocorre para gama. Mostraremos isso de forma mais clara a seguir, provando que as distribuições à posteriori são da mesma família. Mas antes, calcularemos a priori conjunta de $\phi = (\mu, \tau)$:

Dados $\xi_1(\mu|\tau) = \sqrt{\frac{\lambda_0\tau}{2\pi}} \exp \left[-\frac{\lambda_0\tau}{2} (\mu - \mu_0)^2 \right]$ e $\xi_2(\tau) = \frac{\beta_0^{\alpha_0}}{\Gamma(\alpha_0)} \tau^{\alpha_0-1} e^{-\beta_0\tau}$, temos que a distribuição conjunta $\xi(\mu, \tau)$ é:

$$\begin{aligned} \xi(\mu, \tau) &= \xi_1(\mu|\tau) \xi_2(\tau) \\ &= \frac{\beta_0^{\alpha_0} \sqrt{\lambda_0}}{\Gamma(\alpha_0) \sqrt{2\pi}} \tau^{\alpha_0-\frac{1}{2}} e^{-\beta_0\tau} e^{-\frac{\lambda_0\tau(\mu-\mu_0)^2}{2}} \end{aligned} \quad (2)$$

para $\mu \in \mathbb{R}$ e $\tau \in \mathbb{R}_{>0}$.

Definição 1 (Distribuição Normal-Gama:) A distribuição acima é conhecida como Normal-Gama de parâmetros $\mu_0, \lambda_0, \alpha_0, \beta_0$. Pode ser fatorizada facilmente como um produto das densidades de uma Gama(α_0, β_0) e uma Normal($\mu_0, \lambda_0\tau$), pela própria construção. Além disso a região de definição dos parâmetros é: $\mu_0 \in \mathbb{R}$, $\lambda_0 \in \mathbb{R}_{>0}$, $\alpha_0 \in \mathbb{R}_{>0}$ e $\beta_0 \in \mathbb{R}_{>0}$.

¹Trecho retirado da descrição do trabalho.

De fato, trata-se de uma densidade válida pois fatorizando $\tau^{\alpha_0-1/2} = \tau^{\alpha_0-1}\tau^{1/2}$ a integral dupla da função sobre o espaço de definição de ϕ é facilmente calculável via integração iterada de Fubini[2] e resulta em 1:

$$\begin{aligned}\int_0^{+\infty} \int_{-\infty}^{+\infty} \xi(\mu, \tau) d\mu d\tau &= \int_0^{+\infty} \left(\frac{\beta_0^{\alpha_0}}{\Gamma(\alpha_0)} \tau^{\alpha_0-1} e^{-\beta_0 \tau} \int_{-\infty}^{+\infty} \sqrt{\frac{\lambda_0 \tau}{2\pi}} e^{-\frac{\lambda_0 \tau (\mu - \mu_0)^2}{2}} d\mu \right) d\tau \\ &= \int_0^{+\infty} \frac{\beta_0^{\alpha_0}}{\Gamma(\alpha_0)} \tau^{\alpha_0-1} e^{-\beta_0 \tau} d\tau = 1\end{aligned}$$

2.1 Distribuições à posteriori

Com base nos resultados (1) e (2), podemos derivar a distribuição à posteriori conjunta de $\phi = (\mu, \tau)$ e a partir dela, a distribuição condicional de $\mu|\tau$ e as marginais à posteriori de τ e μ .

Notações:

$$\begin{aligned}\bar{x}_n &= \frac{1}{n} \sum_{i=1}^n x_i \\ s_n^2 &= \sum_{i=1}^n (x_i - \bar{x}_n)^2\end{aligned}$$

Teorema 1 [1] *Suponha que X_1, \dots, X_n formam uma amostra aleatória de uma distribuição Normal de média μ desconhecida e precisão τ também desconhecida ($\mu \in \mathbb{R}$ e $\tau \in \mathbb{R}_{>0}$). Se a distribuição conjunta à priori de $\phi = (\mu, \tau)$ é Normal-Gama($\mu_0, \lambda_0, \alpha_0, \beta_0$), então a distribuição à posteriori é Normal-Gama($\mu_1, \lambda_1, \alpha_1, \beta_1$), onde:*

$$\begin{aligned}\mu_1 &= \frac{\lambda_0 \mu_0 + n \bar{x}_n}{\lambda_0 + n} & \lambda_1 &= \lambda_0 + n \\ \alpha_1 &= \alpha_0 + \frac{n}{2} & \beta_1 &= \beta_0 + \frac{1}{2} s_n^2 + \frac{n \lambda_0 (\bar{x}_n - \mu_0)^2}{2(\lambda_0 + n)}\end{aligned}$$

Consequentemente, a distribuição condicional de $\mu|\tau$ é Normal(μ_1, λ_1) e a marginal à posteriori de τ é Gama(α_1, β_1).

Prova:

Assumindo que a distribuição conjunta à posteriori $f(\phi|\vec{X})$ seja realmente Normal-Gama($\mu_1, \lambda_1, \alpha_1, \beta_1$), teremos da Definição (1):

$$\begin{aligned}f(\phi|\vec{X}) &\propto \tau^{\alpha_1-1/2} e^{-\beta_1 \tau} e^{-\frac{\lambda_1 \tau (\mu - \mu_1)^2}{2}} \\ &\propto \tau^{\alpha_1+1/2-1} e^{-\beta_1 \tau} \exp \left[-\frac{\lambda_1 \tau (\mu - \mu_1)^2}{2} \right] \\ &\propto \tau^{\alpha_1-1} e^{-\beta_1 \tau} \tau^{1/2} \exp \left[-\frac{\lambda_1 \tau (\mu - \mu_1)^2}{2} \right]\end{aligned}$$

Daí podemos extrair:

$$\begin{aligned}f(\tau|\vec{X}) &= \int_0^\infty f(\phi|\vec{X}) d\mu \\ &\propto \tau^{\alpha_1-1} e^{-\beta_1 \tau}\end{aligned} \tag{3}$$

e também:

$$\begin{aligned}f(\mu|\tau, \vec{X}) &= \frac{f(\mu, \tau|\vec{X})}{f(\tau|\vec{X})} \\ &\propto \frac{\tau^{\alpha_1-1} e^{-\beta_1 \tau} \tau^{1/2} \exp \left[-\frac{\lambda_1 \tau (\mu - \mu_1)^2}{2} \right]}{\tau^{\alpha_1-1} e^{-\beta_1 \tau}} \\ &\propto \tau^{1/2} \exp \left[-\frac{\lambda_1 \tau (\mu - \mu_1)^2}{2} \right]\end{aligned} \tag{4}$$

De (3) segue que a distribuição à posteriori de $\tau|\vec{X} \sim \text{Gama}(\alpha_1, \beta_1)$ e de (4) segue que $\mu|\tau, \vec{X} \sim \text{Normal}_2(\mu_1, \lambda_1\tau)$. Provamos então a segunda parte do Teorema, mas ainda não provamos que $f(\phi|\vec{X}) \sim \text{Normal-Gama}(\mu_1, \lambda_1, \alpha_1, \beta_1)$. Multiplicando à densidade da distribuição à priori (2) com a função de verossimilhança dos dados (1), teremos:

$$\xi(\mu, \tau)f(\vec{X}|\mu, \tau) \propto \tau^{\alpha_0 + \frac{n}{2} - \frac{1}{2}} e^{-\beta_0\tau} \exp \left[-\frac{\tau}{2} \left(\lambda_0(\mu - \mu_0) + \sum_{i=1}^n (x_i - \mu)^2 \right) \right] \quad (5)$$

Identidade 1

$$\sum_{i=1}^n (x_i - \mu)^2 = s_n^2 + n(\bar{x}_n - \mu)^2$$

Prova:

$$\begin{aligned} \sum_{i=1}^n (x_i - \mu)^2 &= \sum_{i=1}^n (x_i - \bar{x}_n + \bar{x}_n - \mu)^2 \\ &= \sum_{i=1}^n [(x_i - \bar{x}_n)^2 + 2(x_i - \bar{x}_n)(\bar{x}_n - \mu) + (\bar{x}_n - \mu)^2] \\ &= \sum_{i=1}^n (x_i - \bar{x}_n)^2 + 2(\bar{x}_n - \mu) \sum_{i=1}^n (x_i - \bar{x}_n) + \sum_{i=1}^n (\bar{x}_n - \mu)^2 \\ &= \sum_{i=1}^n (x_i - \bar{x}_n)^2 + 2(\bar{x}_n - \mu) \left(\sum_{i=1}^n x_i - n\bar{x}_n \right) + n(\bar{x}_n - \mu)^2 \\ &= \sum_{i=1}^n (x_i - \bar{x}_n)^2 + 2(\bar{x}_n - \mu) (n\bar{x}_n - n\bar{x}_n) + n(\bar{x}_n - \mu)^2 \\ &= \sum_{i=1}^n (x_i - \bar{x}_n)^2 + n(\bar{x}_n - \mu)^2 \end{aligned}$$

Aplicando a Identidade acima na expressão (5), temos:

$$\xi(\mu, \tau)f(\vec{X}|\mu, \tau) \propto \tau^{\alpha_0 + \frac{n}{2} - \frac{1}{2}} e^{-\beta_0\tau} \exp \left[-\frac{\tau}{2} (\lambda_0(\mu - \mu_0) + s_n^2 + n(\bar{x}_n - \mu)^2) \right]$$

Vamos agora para mais manipulações algébricas,

Identidade 2

$$\lambda_0(\mu - \mu_0) + n(\bar{x}_n - \mu)^2 = (\lambda_0 + n)(\mu - \mu_1) + \frac{n\lambda_0(\bar{x}_n - \mu_0)^2}{\lambda_0 + n}$$

Prova:

$$\begin{aligned} \lambda_0(\mu - \mu_0) + n(\bar{x}_n - \mu)^2 &= \lambda_0(\mu^2 + 2\mu\mu_0 + \mu_0^2) + n(\mu^2 - 2\mu\bar{x}_n + \bar{x}_n^2) \\ &= \mu^2(\lambda_0 + n) + \mu(-2\lambda_0\mu_0 - 2n\bar{x}_n) + \lambda_0\mu_0^2 + n\bar{x}_n^2 \\ &= (\lambda_0 + n) \left[\mu^2 - \frac{2\mu(\lambda_0\mu_0 + n\bar{x}_n)}{\lambda_0 + n} \right] + \lambda_0\mu_0^2 + n\bar{x}_n^2 \\ &= (\lambda_0 + n)(\mu - \mu_1)^2 - \mu_1^2(\lambda_0 + n) + \lambda_0\mu_0^2 + n\bar{x}_n^2 \\ &= (\lambda_0 + n)(\mu - \mu_1)^2 + \frac{-(\lambda_0\mu_0 + n\bar{x}_n)^2 + (\lambda_0 + n)(\lambda_0\mu_0^2 + n\bar{x}_n^2)}{\lambda_0 + n} \\ &= (\lambda_0 + n)(\mu - \mu_1)^2 + \frac{-\cancel{\lambda_0^2\mu_0^2} - 2\lambda_0\mu_0n\bar{x}_n - \cancel{n^2\bar{x}_n^2} + \cancel{\lambda_0^2\mu_0^2} + \lambda_0n\bar{x}_n^2 + n\lambda_0\mu_0^2 + \cancel{n^2\bar{x}_n^2}}{\lambda_0 + n} \\ &= (\lambda_0 + n)(\mu - \mu_1)^2 + \frac{n\lambda_0(\bar{x}_n^2 - 2\mu_0\bar{x}_n + \mu_0^2)}{\lambda_0 + n} \\ &= (\lambda_0 + n)(\mu - \mu_1)^2 + \frac{n\lambda_0(\bar{x}_n - \mu_0)^2}{\lambda_0 + n} \end{aligned}$$

Voltando ao trabalho, e aplicando a nova identidade acima temos:

$$\begin{aligned}\xi(\mu, \tau)f(\vec{X}|\mu, \tau) &\propto \tau^{\alpha_0 + \frac{n}{2} - \frac{1}{2}} e^{-\beta_0 \tau} \exp \left[-\frac{\tau}{2} \left(s_n^2 + (\lambda_0 + n)(\mu - \mu_1)^2 + \frac{n\lambda_0(\bar{x}_n - \mu_0)^2}{\lambda_0 + n} \right) \right] \\ &\propto \tau^{\alpha_0 + \frac{n}{2} - \frac{1}{2}} \exp \left[-\beta_0 \tau - \frac{\tau s_n^2}{2} - \frac{\tau n \lambda_0 (\bar{x}_n - \mu_0)^2}{2(\lambda_0 + n)} \right] \exp \left[-\frac{\tau}{2} (\lambda_0 + n)(\mu - \mu_1)^2 \right] \\ &\propto \tau^{\alpha_1 - \frac{1}{2}} e^{-\beta_1 \tau} \exp \left[-\frac{\lambda_1 \tau (\mu - \mu_1)^2}{2} \right]\end{aligned}$$

Esse é o numerador da nossa distribuição à posteriori conjunta. O denominador será a integral do numerador sobre o espaço de definição de $\phi = (\mu, \tau)$, mas o numerador é o núcleo de uma distribuição Normal-Gama($\mu_1, \lambda_1, \alpha_1, \beta_1$), logo, à menos que uma constante que não depende de ϕ , a integral é igual a 1, portanto:

$$\xi(\mu, \tau|\vec{X}) \propto \tau^{\alpha_1 - \frac{1}{2}} e^{-\beta_1 \tau} \exp \left[-\frac{\lambda_1 \tau (\mu - \mu_1)^2}{2} \right], \quad (6)$$

que é núcleo da distribuição almejada, o que finaliza a prova do teorema.

2.2 Análise dos hiperparâmetros

Vejamos novamente as expressões dos parâmetros à posteriori:

$$\begin{aligned}\mu_1 &= \frac{\lambda_0 \mu_0 + n \bar{x}_n}{\lambda_0 + n} & \lambda_1 &= \lambda_0 + n \\ \alpha_1 &= \alpha_0 + \frac{n}{2} & \beta_1 &= \beta_0 + \frac{1}{2} s_n^2 + \frac{n \lambda_0 (\bar{x}_n - \mu_0)^2}{2(\lambda_0 + n)}\end{aligned}$$

As expressões de μ_1 e λ_1 são bastante sugestivas, a primeira é uma média ponderada entre μ_0 e \bar{x}_n onde o peso de μ_0 é o hiperparâmetro λ_0 e o peso de \bar{x}_n é o número de observações n . Ou seja, a média a posteriori vai juntar o conhecimento à priori da média, com o conhecimento obtido a partir dos dados por \bar{x}_n que é estimador de máxima verossimilhança pra média.

Além disso $\lim_{n \rightarrow \infty} \mu_1 = \lim_{n \rightarrow \infty} \left(\frac{\lambda_0}{\lambda_0 + n} \mu_0 + \frac{n}{\lambda_0 + n} \bar{x}_n \right) = \bar{x}_n$,

mostrando que a média à posteriori converge para o estimador de máxima verossimilhança com n grande.

O hiperparâmetro λ_0 também é interpretado como número de pseudo-observações[3] representando de certa forma, observações conhecidas à priori, ou simplesmente, o conhecimento do estatístico que está fazendo a elicitación das priors.

A expressão $\lambda_1 = \lambda_0 + n$ incrementa esse número de pseudo-observações com as novas observações, vindas dos dados.

Também podemos interpretar os parâmetros da Gama nesse contexto de pseudo-observações[3]. Podemos enxergar como se tivéssemos à priori $2\alpha_0$ pseudo-observações² do experimento Normal₂(μ, τ), a variância amostral desse experimento é o valor esperado de τ^{-1} , ou seja $\frac{\beta_0}{\alpha_0}$.

Interpretando α_0 como metade da quantidade de pseudo-observações. O incremento ao observar os dados é de $n/2$ como sugere a expressão à posteriori.

A interpretação de β_0 neste contexto será metade da soma dos erros quadráticos à priori; isso pois, como a variância amostral do pseudo-experimento é β_0/α_0 ao multiplicar pela quantidade de pseudo-observações teremos a soma dos erros quadráticos amostrais que é $2\beta_0$.

A expressão de β_1 deve então simbolizar a soma dos erros quadráticos do experimento à posteriori; Assim, somando à β_0 , $s_n^2/2$ que é metade do erro quadrático dos dados em relação a média amostral, já temos parte da expressão.

² $2\alpha_0$ não necessariamente precisa ser igual a λ_0 . Essa independência é introduzida na interpretação de forma que os pseudo-experimentos Normal e Gamma sejam diferentes.

O terceiro termo $\frac{n\lambda_0(\bar{x}_n - \mu_0)^2}{2(\lambda_0 + n)}$ pode ser entendido como um "termo de interação", e sua existência se justifica pelo fato dos erros anteriores terem sido calculados em relação a médias diferentes: $2\beta_0$ é erro quadrático das pseudo-observações, apesar de não termos explicitado, é óbvio que isso é calculado em relação a μ_0 que pode ser interpretado como média amostral do pseudo-experimento neste contexto. Assim, adicionamos uma penalidade sobre a distância dessa média μ_0 e a observada pelos dados \bar{x}_n , com o termo $\frac{n\lambda_0}{\lambda_0 + n}$ funcionando como uma constante balizadora entre pseudo-observações e observações dos dados de fato.

Essa interpretação do β_0 e β_1 como erros quadráticos faz sentido, pois numa situação onde esses erros são altos, significa que há muita incerteza sobre a distribuição dos dados, e isso é refletido como uma redução do valor esperado de τ , já que β_0, β_1 ficam no denominador de $E(\tau|\vec{X}) = \alpha_1/\beta_1$. Na expressão de $\alpha_1 = \alpha_0 + n/2$ essa noção é ainda mais clara, pois, fixando β_1 , quando maior for o n (quanto mais dados observamos), nossa precisão aumenta pelo fato de termos mais informações.

3 A distribuição marginal de μ

Por definição, a função de densidade da distribuição marginal à posteriori de μ é calculada por:

$$f_\mu(\mu|\vec{X}) = \int_0^\infty \xi(\mu, \tau|\vec{X}) d\tau$$

De (6), temos:

$$\begin{aligned} f_\mu(\mu|\vec{X}) &= c \cdot \int_0^\infty \tau^{\alpha_1 - \frac{1}{2}} e^{-\beta_1 \tau} \exp\left[-\frac{\lambda_1 \tau (\mu - \mu_1)^2}{2}\right] d\tau \\ &= c \cdot \int_0^\infty \tau^{\alpha_1 + \frac{1}{2} - 1} \exp\left[-\tau \left(\beta_1 + \frac{\lambda_1 (\mu - \mu_1)^2}{2}\right)\right] d\tau, \end{aligned}$$

Onde c é a constante da densidade da Normal-Gamma: $c = \frac{\beta_1^{\alpha_1} \lambda_1^{\frac{1}{2}}}{\Gamma(\alpha_1)(2\pi)^{\frac{1}{2}}}$. Note que o integrando acima é o núcleo de uma distribuição Gama $\left(\alpha_1 + \frac{1}{2}, \beta_1 + \frac{\lambda_1 (\mu - \mu_1)^2}{2}\right)$. Assim:

$$\begin{aligned} f_\mu(\mu|\vec{X}) &= c \cdot \frac{\Gamma(\alpha_1 + \frac{1}{2})}{\left(\beta_1 + \frac{\lambda_1 (\mu - \mu_1)^2}{2}\right)^{\alpha_1 + \frac{1}{2}}} \\ &= \frac{\beta_1^{\alpha_1} \lambda_1^{\frac{1}{2}} \Gamma(\alpha_1 + \frac{1}{2})}{\Gamma(\alpha_1)(2\pi)^{\frac{1}{2}}} \cdot \left(\beta_1 + \frac{\lambda_1 (\mu - \mu_1)^2}{2}\right)^{-\alpha_1 - \frac{1}{2}} \\ &= \frac{\beta_1^{-\frac{1}{2}} \lambda_1^{\frac{1}{2}} \Gamma(\alpha_1 + \frac{1}{2})}{\Gamma(\alpha_1)(2\pi)^{\frac{1}{2}}} \left(1 + \frac{\lambda_1 (\mu - \mu_1)^2}{2\beta_1}\right)^{-\alpha_1 - \frac{1}{2}} \\ &= \frac{\alpha_1^{\frac{1}{2}} \beta_1^{-\frac{1}{2}} \lambda_1^{\frac{1}{2}} \Gamma(\frac{2\alpha_1 + 1}{2})}{\Gamma(\frac{2\alpha_1}{2})(2\alpha_1 \pi)^{\frac{1}{2}}} \left(1 + \frac{\lambda_1 \alpha_1 (\mu - \mu_1)^2}{2\alpha_1 \beta_1}\right)^{-\frac{2\alpha_1 - 1}{2}} \end{aligned}$$

Fazendo $\nu = 2\alpha_1$, $c_2 = \left(\frac{\lambda_1 \alpha_1}{\beta_1}\right)^{\frac{1}{2}}$ e $y = c_2(\mu - \mu_1)$, temos:

$$f_\mu(\mu|\vec{X}) = c_2 \frac{\Gamma(\frac{\nu+1}{2})}{\Gamma(\frac{\nu}{2})\sqrt{\nu\pi}} \left(1 + \frac{y^2}{2}\right)^{-\frac{\nu+1}{2}},$$

que é c_2 vezes a densidade da distribuição t de Student[4] com $\nu = 2\alpha_1$ graus de liberdade.

A distribuição marginal de μ nada mais é do que uma t_ν escalonada por c_2^{-1} e deslocada por μ_1 . Isso vem por manipulação direta de y . Com isso, sabendo que $E(y) = 0$ para $\nu > 1$ e $Var(y) = \frac{\nu}{\nu - 2}$ para $\nu > 2$, temos:

$$E(\mu) = c_2^{-1}E(y) + \mu_1 = \mu_1, \text{ para } \alpha_1 > \frac{1}{2}$$

$$Var(\mu) = c_2^{-2}Var(y) = \frac{\beta_1}{\lambda_1\alpha_1} \frac{\alpha_1}{\alpha_1 - 1} = \frac{\beta_1}{\lambda_1(\alpha_1 - 1)} \text{ para } \alpha_1 > 1$$

Todos esses resultados podem ser derivados de forma análoga para a distribuição marginal à priori de μ , bastando trocar $\mu_1, \lambda_1, \alpha_1, \beta_1$ respectivamente por $\mu_0, \lambda_0, \alpha_0, \beta_0$. Verbalizando melhor, temos:

Teorema 2 (Marginal à priori de μ) A distribuição de $\left(\frac{\lambda_0\alpha_0}{\beta_0}\right)^{\frac{1}{2}} (\mu - \mu_0)$ é t de Student com $2\alpha_0$ graus de liberdade e:

$$E(\mu) = \mu_0, \text{ para } \alpha_1 > \frac{1}{2}$$

$$Var(\mu) = \frac{\beta_0}{\lambda_0(\alpha_0 - 1)} \text{ para } \alpha_1 > 1$$

4 O Dilema da Palmirinha

Palmirinha anda preocupada com a concentração de amido em sua pamonha. Ela pede para Valciclei, seu assistente, amostrar $n = 10$ pamonhas e medir sua concentração de amido.

Ele, muito prestativo, rapidamente faz o experimento, mas, porque comeu todas as amostras depois que foram medidas, precisou fazer uma visita de emergência ao banheiro. Desta feita, apenas teve tempo de anotar em um papel a média e variância amostrais, $\bar{x}_n = 8.307849$ e $\bar{s}_n^2 = 7.930452$.

Palmirinha tem uma reunião com investidores em pouco tempo, então decide voltar aos seus tempos de bayesiana *old school* e analisar os dados utilizando prioris conjugadas. Ela supõe que a concentração de amido segue uma distribuição normal com parâmetros μ e τ e que as observações feitas por Valciclei são independentes entre si. Ela suspeita que a concentração de amido na pamonha fique em torno de 10 mg/L, com desvio padrão de 2 mg/L. Com sua larga experiência na confecção de pamonhas, ela suspeita ainda que o coeficiente de variação da concentração de amido seja em torno de 1/2. Palmirinha tem um quadro em seu escritório, que diz

$$cv = \frac{\sigma}{\mu}.$$

4.1 Posteriors

Sabendo que $\mu|\vec{X} \sim \left(\frac{\lambda_1\alpha_1}{\beta_1}\right)^{-\frac{1}{2}} t_{2\alpha_1} + \mu_1$ e que, pelo Teorema (1), temos

$$\begin{aligned} \mu_1 &= \frac{\lambda_0\mu_0 + n\bar{x}_n}{\lambda_0 + n} & \lambda_1 &= \lambda_0 + n \\ \alpha_1 &= \alpha_0 + \frac{n}{2} & \beta_1 &= \beta_0 + \frac{1}{2}s_n^2 + \frac{n\lambda_0(\bar{x}_n - \mu_0)^2}{2(\lambda_0 + n)}, \end{aligned}$$

, dada uma atribuição de valores para os hiperparâmetros $\mu_0, \lambda_0, \alpha_0, \beta_0$, a distribuição à posteriori de μ fica definida, pois tais valores mais as estatísticas suficientes calculadas por Valciclei (\bar{x}_n e s_n^2) definem de forma fechada $\mu_1, \lambda_1, \alpha_1, \beta_1$ e consequentemente, a distribuição $\mu|\vec{X}$.

Analogamente, com tais informações, poderíamos gerar a distribuição de $\tau|\vec{X}$, pois esta é $\text{Gama}(\alpha_1, \beta_1)$ que é está definida com as informações de Valciclei e os hiperparâmetros.

4.2 Intervalos de Credibilidade

Queremos ajudar a Palmirinha a encontrar $a, b \in \mathbb{R}$, $a < b$ de modo que $\Pr(\mu \in (a, b) | \vec{X}) = 0.95$. De modo geral, sabendo que $\mu|\vec{X} \sim \left(\frac{\lambda_1\alpha_1}{\beta_1}\right)^{-\frac{1}{2}} t_{2\alpha_1} + \mu_1$, se quisermos $a < b$ na qual $\Pr(\mu \in (a, b) | \vec{X}) = \gamma$, com $0 < \gamma < 1$, é conveniente tratar o problema de forma simétrica já que estamos falando da distribuição t, sendo

assim, tomemos c , de tal forma que $\Pr(-c < t_{2\alpha_1} < c) = \gamma$; Se $T_{2\alpha_1}$ é a função de densidade acumulada da $t_{2\alpha_1}$, então temos:

$$\begin{aligned}\Pr(-c < t_{2\alpha_1} < c) = \gamma &\Leftrightarrow T_{2\alpha_1}(c) - T_{2\alpha_1}(-c) = \gamma \\ &\Leftrightarrow T_{2\alpha_1}(c) - (1 - T_{2\alpha_1}(c)) = \gamma \\ &\Leftrightarrow 2T_{2\alpha_1}(c) - 1 = \gamma \\ &\Leftrightarrow T_{2\alpha_1}(c) = \frac{1 + \gamma}{2} \\ &\Leftrightarrow c = T_{2\alpha_1}^{-1}\left(\frac{1 + \gamma}{2}\right),\end{aligned}$$

onde a última expressão é calculada computacionalmente ou por consulta em tabelas.

Sabendo que $\left(\left(\frac{\lambda_1\alpha_1}{\beta_1}\right)^{\frac{1}{2}}(\mu - \mu_1)\right) \sim t_{2\alpha_1}$, podemos definir a e b via:

$$\begin{aligned}\Pr\left[-c < \left(\frac{\lambda_1\alpha_1}{\beta_1}\right)^{\frac{1}{2}}(\mu - \mu_1) < c\right] &= \gamma \\ \Leftrightarrow \Pr\left[-c\left(\frac{\lambda_1\alpha_1}{\beta_1}\right)^{-\frac{1}{2}} < \mu - \mu_1 < c\left(\frac{\lambda_1\alpha_1}{\beta_1}\right)^{-\frac{1}{2}}\right] &= \gamma \\ \Leftrightarrow \Pr\left[-c\left(\frac{\lambda_1\alpha_1}{\beta_1}\right)^{-\frac{1}{2}} + \mu_1 < \mu < c\left(\frac{\lambda_1\alpha_1}{\beta_1}\right)^{-\frac{1}{2}} + \mu_1\right] &= \gamma\end{aligned}$$

Assim, podemos fazer:

$$\begin{aligned}a &= -c\left(\frac{\lambda_1\alpha_1}{\beta_1}\right)^{-\frac{1}{2}} + \mu_1 \\ b &= c\left(\frac{\lambda_1\alpha_1}{\beta_1}\right)^{-\frac{1}{2}} + \mu_1, \\ \text{onde } c &= T_{2\alpha_1}^{-1}\left(\frac{1 + \gamma}{2}\right)\end{aligned}$$

Por construção, $a < b$ e $P(a < \mu < b|\vec{X}) = \gamma$

Para elicitação dos hiperparâmetros à priori, começemos com a distribuição marginal de μ , a qual palmirinha acredita ter média 10 e variância 4. Podemos então igualar os momentos de tal distribuição descritos no Teorema (2), e chegar a um sistema de equações que vai resolver nossa situação pra μ_0 .

$$\begin{aligned}E(\mu) &= \mu_0 = 10 \\ Var(\mu) &= \frac{\beta_0}{\lambda_0(\alpha_0 - 1)} = 4\end{aligned}$$

Já definimos então $\mu_0 = 10$. Para os outros parâmetros vamos trabalhar com τ . A única informação que temos sobre ele é o coeficiente de variação igual a $1/2$. O cv é uma função de τ , e podemos invertê-la de forma a fazer τ como função do $cv=1/2$:

$$\begin{aligned}cv = \frac{\sigma}{\mu} &\Rightarrow cv = \frac{1/\sqrt{\tau}}{\mu} \\ &\Rightarrow \sqrt{\tau} = \frac{1}{cv \cdot \mu} \\ &\Rightarrow \tau = \left(\frac{2}{\mu}\right)^2\end{aligned}$$

Uma coisa razoável a se fazer, para não nos preocuparmos com a distribuição induzida da expressão acima, é considerar μ como um valor fixo razoável. No caso, usaremos $E(\mu) = 10$, que é a informação da Palmirinha. Sendo assim, o valor esperado $E(\tau) = \frac{4}{100} = \frac{1}{25}$. Usaremos tal valor para igualar ao momento do parâmetro de precisão. Como τ tem distribuição $\text{Gamma}(\alpha_0, \beta_0)$, temos:

$$\frac{\alpha_0}{\beta_0} = \frac{1}{25}$$

Vamos agora fixar um valor razoável para α_0 , que apesar de ser arbitrário, não pode ser muito grande pois está ligado com a quantidade de informação que temos. na interpretação das pseudo-observações, α_0 está ligado à quantidade de pseudo-experimentos ($2\alpha_0$), que no nosso caso está representando a experiência da Palmirinha, que apesar de ser vasta na área de confecção de pamonhas, vamos adotar α_0 baixo, para dar mais flexibilidade para a posteriori. Para que os momentos de μ estejam bem definidos é preciso que α_0 seja maior que 1, usaremos o próximo inteiro 2, para manter a integridade da interpretação de pseudo-experimentos.

Sendo assim, $\beta_0 = 25\alpha_0 = 50$

Na interpretação que demos sobre β_0 ele era metade da soma dos erros quadráticos à priori. Como temos $2\alpha_0/2 = 4$ pseudo-observação, a soma quadrática mencionada nada mais é do que a variância amostral³ desses experimentos vezes a quantidade de experimentos, ou seja $25 \cdot 4 = 100$, que é consistente com o que foi dito.

Tendo α_0, β_0 , encontramos λ_0 facilmente pela expressão que já tínhamos da variância de μ :

$$\begin{aligned} \text{Var}(\mu) &= \frac{\beta_0}{\lambda_0(\alpha_0 - 1)} = 4 \Rightarrow \frac{50}{\lambda_0} = 4 \\ &\Rightarrow \lambda_0 = 50/4 = 12.5 \end{aligned}$$

Tendo então $(\mu_0, \lambda_0, \alpha_0, \beta_0) = (10, 12.5, 2, 50)$, usando os dados de Valciclei no Teorema 1 obtemos, $(\mu_1, \lambda_1, \alpha_1, \beta_1) \approx (9.25, 22.5, 7, 61.92)$, o cálculo foi feito com o código abaixo escrito em Python 3.7, que além de fazer isso, calcula o intervalo de credibilidade com $\gamma = 0.95$ como descrito anteriormente.

Segue o script:

```
#Hiperparametros a priori
mu0 = 10
alpha0 = 2
beta0 = 25*alpha0
lambda0 = beta0/(4*(alpha0-1))
print(f"mu0 = {mu0}\nlambda0 = {lambda0}\nalpha0 = {alpha0}\nbeta0 = {beta0}\n\n")

#Estatisticas Suficientes
xn = 8.307849
sn = 7.930452
n = 10

#Hiperparametros a posteriori
mu1 = (lambda0*mu0+n*xn)/(lambda0+n)
lambda1 = lambda0+n
alpha1 = alpha0+n/2
beta1 = beta0 + sn/2 + (n*lambda0*(xn-mu0)**2)/(2*(lambda0+n))
print(f"mu1 = {mu1}\nlambda1={lambda1}\nalpha1 = {alpha1}\nbeta1 = {beta1}\n\n")

#Intervalo de credibilidade
gamma = 0.95
from scipy.stats import t
c = t.ppf((1+gamma)/2, df=2*alpha1)
c2 = (lambda1*alpha1/beta1)**(-1/2)
a = -c*c2+mu1
b = c*c2+mu1

print(f"P({a} < mu < {b}) = {gamma}")
```

A saída no console referente ao intervalo de credibilidade foi:

$$P(7.903138300680498 < \mu < 10.592727477097279) = 0.95$$

Portanto, dadas as condições sobre os hiperparâmetros à priori e as estatísticas de Valciclei, com $a \approx 7.9$ e $b \approx 10.59$, temos $P(a < \mu < b | \vec{X}) \approx 0.95$

³Usamos 25, que é o a variância induzida pelo cv.

Referências

- [1] M.H. DeGroot and M.J. Schervish. *Probability and Statistics, 4th ed.*, pages 495–505. Addison-Wesley, 2012.
- [2] Wikipedia. Fubini's theorem — Wikipedia, the free encyclopedia. <http://en.wikipedia.org/w/index.php?title=Fubini's%20theorem&oldid=975839217>, 2020.
- [3] Wikipedia. Normal-gamma distribution, Interpretation of parameters — Wikipedia, the free encyclopedia. https://en.wikipedia.org/wiki/Normal-gamma_distribution?oldformat=true#Interpretation_of_parameters, 2020.
- [4] Wikipedia. Student's t-distribution — Wikipedia, the free encyclopedia. <http://en.wikipedia.org/w/index.php?title=Student's%20t-distribution&oldid=981752965>, 2020.